

Visión Artificial

Tema 13. Extracción de características. Procesamientos multiescala y métodos avanzados

Índice

Esquema

Ideas clave

13.1. ¿Cómo estudiar este tema?

13.2. Introducción a la extracción de características basada en procesamiento multiescala

13.3. Definición de transformada Wavelet

13.4. Filtros de Gabor

13.5. Transformada SIFT

A fondo

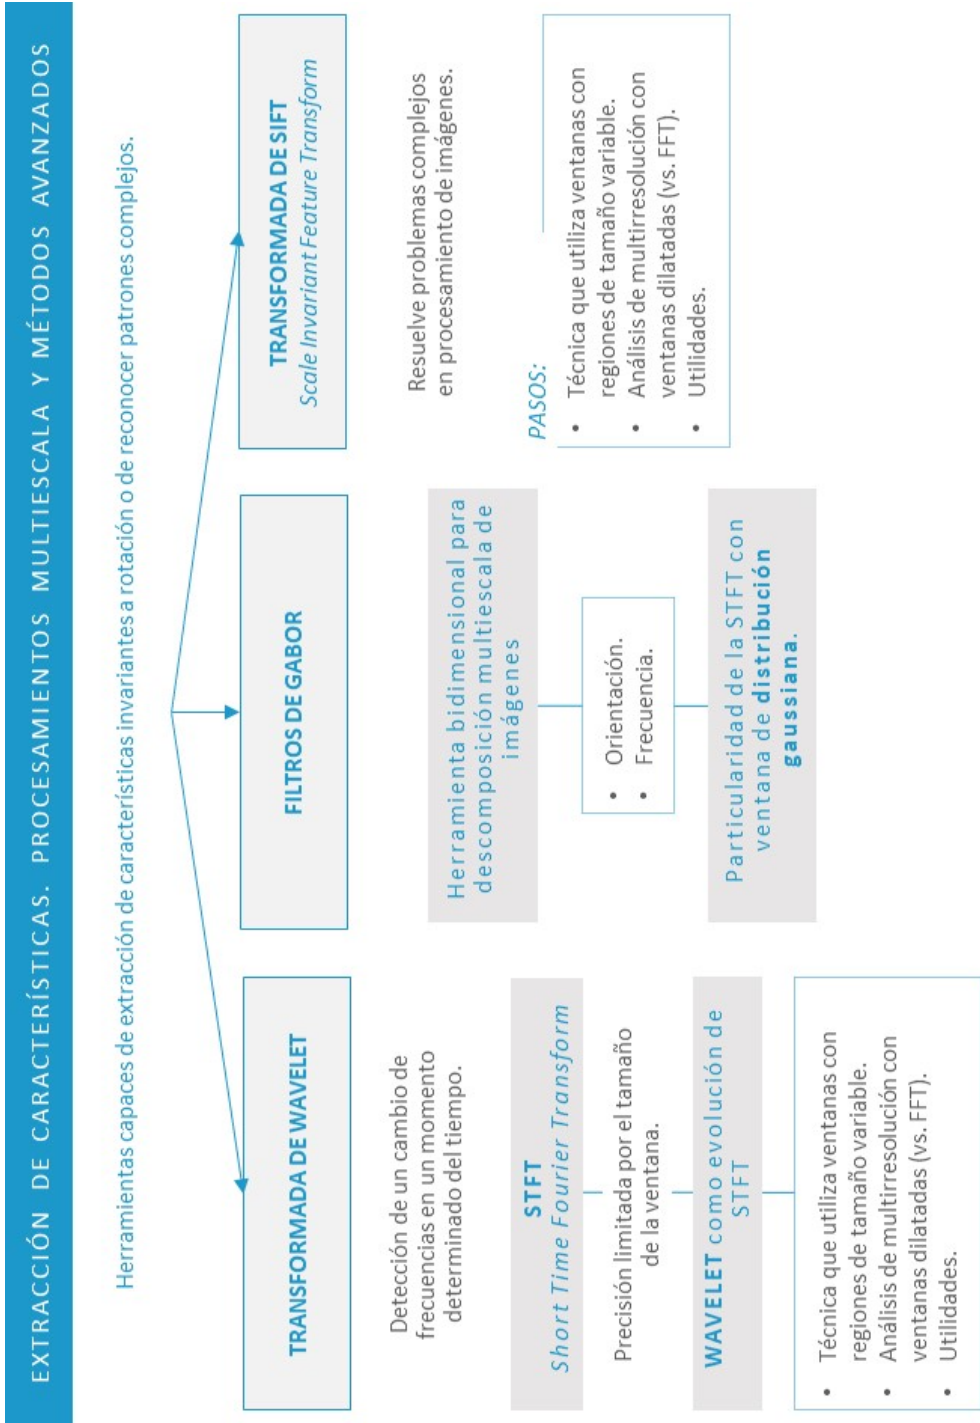
Transformada Wavelet

Transformada Gabor

Transformada SIFT

Bibliografía

Test



13.1. ¿Cómo estudiar este tema?

Para estudiar este tema deberás leer con atención las ideas clave que se desarrollan a continuación.

Sin llegar a entender la matemática detrás de estos complejos algoritmos de extracción de características, se dotará de los conceptos necesarios para entender la funcionalidad de las Wavelets, filtros de Gabor y algoritmo SIFT.

Las nociones aquí presentadas te permitirán entender en qué caso y qué algoritmo deberás de emplear y qué parámetros necesitas para su correcto funcionamiento.

13.2. Introducción a la extracción de características basada en procesamiento multiescala

De todos los métodos presentados para la extracción de características, la mayoría de ellos carece de la posibilidad de reconocer patrones más complejos y elaborados como puede ser la identificación de un objeto. El análisis de imágenes basado en histogramas de color, variaciones de las intensidades o incluso reconocimiento de patrones para identificar una textura sufren, en muchos casos, de limitaciones para identificar la rotación de un objeto en una imagen o el hecho de que parte de un objeto esté oculto.

Un problema tan sencillo de definir como puede ser la identificación de un objeto independientemente de su rotación o traslación (como se puede ver en la imagen a continuación), es altamente complejo usando las extracciones de características presentadas hasta ahora, por no decir imposible.




Figura 1. Ejemplo de funcionamiento del algoritmo SIFT para la traslación de una imagen. Fuente:

<http://timothykurek.com/10-sift-image-processing/introduction-to-sift-scale-invariant-feature-transform-opencv-on-sift-image-processing/>

Es por eso que surgen otras herramientas como son la transformada Wavelet, los filtros de Gabor o el algoritmo SIFT (*Scale Invariant Feature Transformation*) que son capaces de proporcionar características más robustas para:

- ▶ Mejorar la información extraída de una imagen y proporcionar una visión más detallada de texturas, variabilidad de la imagen u objetos presentes.
- ▶ Proporcionar características invariantes al cambio de escala, rotación y ruido que pueda estar presente en una captura de imagen.
- ▶ Resolver, en definitiva, problemas más avanzados de procesamiento de imagen.

No obstante, las matemáticas necesarias para comprender el funcionamiento de estos algoritmos son muy avanzadas y no se presentarán de forma detallada en este tema. Se planteará la **descripción de estos algoritmos de forma funcional** entendiendo qué hacen, cómo y por qué esto supone una ventaja con respecto a otros algoritmos de extracción de características.

Entre las aplicaciones más comunes de estos algoritmos están:

- ▶ Identificar a las personas en función de su huella u iris, también denominados **algoritmos de biometría**. La identificación basada en características biométricas precisa de matemática y algoritmos avanzados para procesar la imagen más allá de una variación de intensidades. Gracias a las Wavelets y los filtros de Gabor, podemos extraer características invariantes al reescalado del iris (hay que considerar que el iris y la pupila varían su tamaño casi un número infinito de veces al día, lo que dificulta el reconocimiento), intensidad de brillo así como el color de la imagen.

- ▶ El capturar con nuestro móvil una secuencia de fotos y hacer una panorámica. Los algoritmos como SIFT son capaces de encontrar esos puntos en común entre dos fotos y aplicar las transformadas necesarias de rotación y reescalado para poder fusionar las imágenes correctamente.
- ▶ La identificación de monedas en una máquina de expendedoras (vending). En algunas se captura una foto de la moneda (la cual no presenta siempre el mismo grado de rotación) y con ello se realiza la identificación del valor de la misma. Esta técnica requiere de Wavelets para extraer características invariantes a la rotación.

13.3. Definición de transformada Wavelet

Existen numerosas aproximaciones para describir las Wavelets, en algunos libros conocidas como «ondículas» incluso «onditas». En este tema, y puesto que previamente hemos presentado en detalle la transformada de Fourier, vamos a partir de esta misma transformada para entender qué aspecto del que carecen las transformadas de Fourier pretenden cubrir las Wavelets.

Recordemos brevemente que la **transformada de Fourier** permite descomponer una señal en sus componentes sinusoidales de diferentes frecuencias; en otras palabras: puede pensarse que es una técnica matemática para transformar el punto de vista de una señal desde la base de tiempo a la base de la frecuencia. La transformada de Fourier cubre un amplio espectro de problemas, sin embargo, su **limitación** comienza cuando, dada una señal con gran variabilidad de frecuencia, no se puede determinar en qué momento del tiempo sucedió dicha variación de frecuencia.

Hay que recordar que la transformada de Fourier está pensada únicamente para el análisis de frecuencias de una señal temporal y, para ello, se olvida de toda componente temporal analizando las componentes espectrales (de frecuencia).

Cuando se observa una señal, producto de la transformación de Fourier, resulta imposible determinar cuándo ocurre un determinado evento o cuándo está presente una determinada frecuencia si las propiedades de la señal que se está analizando no cambian demasiado en el tiempo, es decir, si se está trabajando con una **señal estacionaria**.

Esta desventaja no resulta muy relevante, como en el caso de señales periódicas, por ejemplo. Sin embargo, un importante número de señales de interés presentan características no estacionarias o transitorias, tales como: una tendencia, cambios abruptos, comienzos o finales de eventos, etc.

A menudo, estas características no estacionarias resultan ser las secciones más interesantes de las señales, y la transformada de Fourier no está preparada para detectarlas o analizarlas.

Evolucionar la transformada de Fourier: STFT

En un esfuerzo por corregir la deficiencia presentada en el punto previo, en 1946 Denis Gabor adaptó la transformada de Fourier para poder analizar una pequeña sección de la señal en un determinado tiempo mediante una especie de ventana. Esta adaptación es la que se conoce como STFT (*Short Time Fourier Transform*), la cual lleva una señal del plano del tiempo al plano bidimensional de tiempo y frecuencia.




Figura 2. Funcionamiento visual de la Short Time Fourier Transform. Fuente:

https://www.researchgate.net/figure/Short-time-Fourier-transform-STFT-with-envelope-and-two-sample-overlap_fig7_231828310

En la anterior imagen se puede ver que, donde para cada ventana de tiempo, se calcula la transformada de Fourier (FFT), analizando posteriormente las componentes espectrales (de potencia por ventana)

Es importante mencionar que la STFT representa un compromiso entre el dominio del tiempo y el de la frecuencia de una señal, proporcionando información acerca de cuándo y a qué frecuencia de una señal ocurre un determinado evento. Sin embargo, solamente se puede obtener dicha información con una **precisión limitada**, la cual está acotada por el tamaño de la ventana.

A continuación se presentan dos ejemplos de STFT sobre bioseñales, concretamente electromiogramas. En el caso de la izquierda, se aprecia cómo la señal, a medida que pasa el tiempo, posee diferentes componentes en frecuencia. Dichas componentes no se habrían apreciado con un análisis en frecuencia basado en Fourier, ya que no habría tenido en cuenta esa variación temporal de frecuencias. En resumen, en esta comparativa podemos ver cómo, en función del tiempo, se ven las diferentes componentes espectrales.




Figura 3. Dos visualizaciones de STFT de señales unidimensionales provenientes de electromiogramas.

Fuente: Adaptado de <https://es.mathworks.com/matlabcentral/fileexchange/45405-short-time-fourier-transform--stft-?focused=3809422&tab=function> y <https://stackoverflow.com/questions/14586685/stft-computation-without-using-spectrogram-function>

Mientras que el compromiso entre la información del tiempo y la frecuencia puede resultar útil, el inconveniente surge cuando, una vez que se escoge un determinado tamaño para la ventana de tiempo, dicha ventana es la misma para todas las frecuencias. Muchas señales requieren un acercamiento más flexible, de tal modo que sea posible **variar el tamaño de la ventana** para determinar con mayor precisión el tiempo o la frecuencia.

Wavelets como evolución de STFT

El análisis Wavelet representa el paso lógico siguiente a la STFT; es una técnica que, mediante ventanas con **regiones de tamaño variable**, permite:

- ▶ El uso de intervalos grandes de tiempo en aquellos segmentos en los que se requiere mayor precisión en baja frecuencia.
- ▶ Regiones más pequeñas donde se requiere información en alta frecuencia.




Figura 4. Comparativa de esquema entre STFT y Análisis con Wavelets. Fuente: Adaptado de https://www.researchgate.net/figure/a-STFT-with-fixed-aspect-ratio-b-wavelet-transform-with-variable-aspect-ratio_fig2_228413897

Esta transformada es eficiente para el análisis local de señales no estacionarias y de rápida transitoriedad. Al igual que la transformada de Fourier con ventana, mapea la señal en una representación de tiempo-escala; la diferencia está en que la transformada Wavelet provee **análisis de multirresolución con ventanas dilatadas**:

- ▶ El análisis de las frecuencias de mayor rango se realiza usando ventanas angostas.
- ▶ El análisis de las frecuencias de menor rango se hace utilizando ventanas anchas.




Figura 5. Resumen con las Wavelets más comunes. Fuente:

<http://www.continuummechanics.org/wavelets.html>

Una forma sencilla de comprender el modo de operación de esta transformada es pensar que la señal en base de tiempo es pasada por varios filtros paso bajo y paso alto, los cuales permiten separar las porciones de la señal de alta frecuencia de aquellas de baja frecuencia.

Este procedimiento se repite cada vez sobre algunas porciones de la señal correspondientes a aquellas frecuencias que han sido eliminadas de la señal original.




Figura 6. Ejemplo de descomposición multiescala en sus componentes horizontales, verticales y diagonales. Fuente: <https://es.mathworks.com/help/wavelet/ug/two-dimensional-discrete-wavelet-analysis.html>

Utilidades de la transformada Wavelet

Como ya se ha mencionado anteriormente, el procesamiento de señales a través de Wavelets tiene innumerables aplicaciones en diversos ámbitos de la ciencia e ingeniería. A continuación se describe una lista de ejemplos:

- ▶ Detección de **discontinuidades o de puntos de quiebre** en señales, en una o varias dimensiones: resulta de gran utilidad, en especial en el tratamiento de imágenes, en donde interesa detectar la frontera entre colores y formas, o también en sistemas altamente dinámicos, en donde concierne determinar cuándo o dónde se producen los cambios.
- ▶ Estudio de fractales: mediante Wavelets se puede reconocer un **patrón repetitivo** en una señal o imagen, lo que la convierte en una herramienta poderosa en el estudio de fractales.
- ▶ Identificación de frecuencias puras: como se trata de una transformada compuesta por una base ortogonal de señales (análoga con la base sinusoidal de Fourier), también pueden ser utilizadas para **estudiar el contenido espectral** de señales.
- ▶ Eliminación de ruido: el análisis de señales mediante Wavelet también permite la **eliminación o filtrado de ruido** tanto en señales unidimensionales como en imágenes (bidimensionales).

- ▶ **Compresión** de imágenes: se trata de una de las aplicaciones más importantes de Wavelets, se realiza mediante el análisis en dos dimensiones.
- ▶ Aplicaciones en medicina: se ha incorporado el análisis con Wavelets a señales biológicas, permitiendo interpretar los resultados de exámenes médicos, facilitando el **diagnóstico de las enfermedades**. Por ejemplo, se ha aplicado con éxito en el análisis de electroencefalogramas, debido a que la naturaleza de este tipo de señales son altamente no estacionarias (impidiendo el uso de Fourier):
 - Las Wavelets permiten transformar la señal al dominio tiempo-frecuencia, relacionando el contenido espectral al momento de su ocurrencia. Ha sido aplicado en el diagnóstico de pacientes con alzheimer, enfermedad que hasta ahora era difícil de diagnosticar. El procedimiento que se realiza es entrenar redes neuronales con los datos obtenidos (a través de Wavelets de multiresolución) de pacientes de los que se sabe padecen la enfermedad, para luego introducir las mediciones de aquellos que se realizan exámenes, y de este modo poder establecer si se siguen los mismos patrones.

13.4. Filtros de Gabor

Los filtros de Gabor son una particularidad de la STFT donde la ventana tiene una distribución gaussiana. Detrás de los filtros de Gabor existe una explicación basada en la naturaleza. De hecho, tanto las Wavelets como los filtros de Gabor son **los que mejor imitan el funcionamiento del ojo natural**.

Desde la década de 1980 es bien conocido que las células simples de la corteza visual de nuestro cerebro presentan una sensibilidad especial hacia la orientación y la frecuencia espacial en una escena visual.

Por **orientación** nos referimos al ángulo formado por un objeto y un eje de referencia elegido arbitrariamente, mientras que la **frecuencia** espacial da cuenta de la repetición de un patrón en el espacio, medido en unidades inversas de longitud.

Dichas células aparecían en agrupaciones binarias, donde cada par era capaz de detectar una cierta orientación y frecuencia. Sin embargo, había una diferencia de fase de $\pi/2$ radianes entre ambas células, es decir: mientras la primera podía detectar objetos simétricos o repetidos (líneas paralelas), la otra se encargaba de los objetos asimétricos.

Al contrario que en las Wavelets, que son unidimensionales, los filtros de Gabor son bidimensionales, convirtiéndolo en una excelente herramienta para la descomposición multiescala de imágenes.




Figura 7. Representación de la parte real de un filtro de Gabor. Fuente:

<http://www.di.uniba.it/~ig/GaborFilter/html/filtro.html>




Figura 8. Parte real de los filtros Gabor con cuatro diferentes frecuencias y ocho orientaciones. Fuente:

https://www.researchgate.net/figure/Gabor-wavelets-filter-bank-which-has-been-used-for-the-active-basis-model_fig2_262781727

El concepto esencial detrás de los filtros de Gabor es similar al de las Wavelets y al de Fourier: descomponer una imagen o una señal en determinadas componentes y, con ello, poder definir unas características que proporcionen información adicional de la imagen para su mejor entendimiento. Si una imagen se convoluciona con todas y cada una de las funciones arriba representadas, se detectarán no solo bordes y contornos, sino también diferentes texturas o patrones.

Las aplicaciones más comunes de los filtros de Gabor, más allá de la detección de texturas, están relacionadas con la **biometría** o, lo que es lo mismo, la verificación e identificación de usuarios con base en patrones biométricos como la huella o el iris. Concretamente, son huella e iris los que más emplean filtros de Gabor para el correcto funcionamiento.

A continuación se presenta un ejemplo de cómo se aplican los filtros de Gabor (y el resultado obtenido) en un caso de uso real de biometría de iris. El objetivo es reducir la complejidad de textura del iris a un patrón que pueda ser comparado con otros patrones mediante una distancia sencilla (como puede ser la distancia de Hamming). De ahí que el resultado, después de obtener el filtro de Gabor, parezca un código QR.




Figura 9. Funcionamiento de un sistema biométrico basado en iris con filtros de Gabor. Fuente:

https://www.researchgate.net/publication/309659737_Unlinkable_improved_multi-biometric_iris_fuzzy_vault

En esta imagen vemos:

- ▶ Imagen original **(a)**.
- ▶ Imagen segmentada, detectando la región de iris a procesar **(b)**.
- ▶ La textura del iris convertida a coordenadas rectangulares **(c)**.
- ▶ Textura con alto contraste **(d)**.
- ▶ Código de iris después de aplicar filtro de Gabor **(e)**.
- ▶ Código de iris después de aplicar una wavelet cuadrática **(f)**.

13.5. Transformada SIFT

Esta transformada es de las que tiene más utilidad hoy en día y que resuelve problemas muy complejos en procesamiento de imágenes. Uno de ellos es el de encontrar objetos parcialmente ocultos en imágenes. Vamos a verlo con el siguiente ejemplo:



Figura 10. Localización de objetos parcialmente ocultos en una imagen. Fuente: <http://eric-yuan.me/sift/>

A la izquierda de esta imagen se pueden ver dos objetos: una rana y una máquina de tren. En la imagen de la derecha, hay una rana (oculta detrás de un objeto negro), así como las dos máquinas de tren (una de ellas incluso en vertical).

Si intentamos responder a la pregunta: «¿Están los objetos tren y rana dentro de la imagen?», no podríamos dar respuesta con ninguno de los métodos presentados hasta este tema. Con las Wavelets y filtros de Gabor podríamos habernos acercado a detectar alguna característica común, pero en ningún momento con la precisión

que el algoritmo SIFT lo realiza. Las iniciales del algoritmo significan *Scale Invariant Feature Transform* y proporciona el siguiente resultado. En ella se aprecian varios recuadros y colores:

- ▶ Cada **color** corresponde con un objeto encontrado: amarillo y verde para las máquinas de tren, rojo para la rana.
- ▶ El **recuadro más grande** indica dónde está el objeto en su totalidad.
- ▶ Los recuadros más pequeños indican las **características** que se han detectado tanto en las imágenes de los objetos originales como en la imagen donde se encuentran los objetos ocultos.
- ▶ Cada uno de estos recuadros posee un tamaño y una orientación, ambos parámetros son devueltos por el algoritmo SIFT.



Figura 11. Resultado del algoritmo SIFT. Fuente: <http://eric-yuan.me/sift/>

En esta imagen se ve en diferentes colores y con un gran recuadro la ubicación de los objetos buscados. Además, se presentan también, con recuadros más pequeños, las características detectadas.

Veamos ahora el **funcionamiento de este algoritmo**.

Para obtener un conjunto de descriptores SIFT de una imagen es necesario, por un lado, obtener los puntos característicos y después, para cada punto de interés, calcular su vector descriptor a partir de la información de los píxeles que lo rodean. SIFT fue propuesto para imágenes en escala de grises, por lo que el vector de características de 128 elementos que define cada píxel contiene información sobre cómo se distribuyen los niveles de intensidad alrededor de cada punto de interés previamente obtenido.

Por lo tanto, el algoritmo consta de dos partes claramente diferenciadas:

- ▶ Obtención de los puntos característicos.
- ▶ Descripción de la región alrededor de cada punto de interés.

La **obtención de los puntos característicos** o puntos de interés, a los que habitualmente se llama en inglés *keypoints*, consiste en detectar aquellas regiones de la imagen en las que se producen diferencias de gradiente significativas a ambos lados de dicho punto. Si el método solamente hiciera eso, se podría pensar que esta etapa se realizaría utilizando un detector de esquinas. SIFT propone no detectar únicamente esquinas, sino *blobs*, y hacerlo de manera que esa detección sea consistente cuando el punto característico aparezca a diferentes escalas.

La diferencia entre una esquina (*corner*) y un blob se explica a continuación: si nos fijamos en su definición, una **esquina** es un punto o un área pequeña en una imagen donde confluyen, al menos, dos bordes. Se define un **blob** como una región de una imagen que se caracteriza porque algunas de sus propiedades se mantienen aproximadamente constantes. Dentro del contexto de la detección de puntos característicos (*keypoints*), la propiedad que se suele considerar constante en un *blob* es la **similitud en su nivel de gris**, típicamente medida a partir de la variación del gradiente en esa región a lo largo de diferentes direcciones.

En resumen, buscamos puntos que pueden ser pequeñas regiones con un nivel de intensidad estable y alrededor de las cuales se produce una variación significativa del gradiente en más de una dirección.

Para obtener el **descriptor de cada punto característico**, se calcula un histograma de direcciones del gradiente local alrededor del punto de interés. El descriptor que se obtiene se convierte en invariante a la escala al normalizar el tamaño del vecindario local al punto de interés en función de ella. Además, es invariante a la rotación porque se determina la orientación dominante de los vectores del gradiente en el vecindario del punto característico, y se aplica dicha información para orientar la rejilla utilizada para calcular el histograma.

En resumen, los pasos a seguir son:

- ▶ Detección de extremos en el espacio-escala: se buscan puntos de interés en toda la imagen y en todas las escalas consideradas utilizando una diferencia de gaussianas.
- ▶ Localización precisa de puntos característicos: para cada uno de los puntos de interés anteriores se ajusta un modelo que permite determinar su localización y escala. Además, se seleccionan los puntos característicos, keypoints, eliminando los que están próximos a los bordes o tienen bajo contraste.
- ▶ Asignación de la orientación: a cada punto característico se le asigna una o varias orientaciones en función de las direcciones del gradiente local. Esta orientación, conjuntamente con la ubicación y la escala calculadas anteriormente, permite que el descriptor sea invariante a estas tres situaciones.
- ▶ Descripción del punto característico: alrededor de cada punto característico se miden los gradientes locales de la imagen y se utiliza su histograma para obtener una representación de esa región que es robusta a cambios significativos en la iluminación y a pequeñas distorsiones en la forma.




Figura 12. Detección con SIFT de objetos complejos (y sin formas definidas) en una imagen. Fuente:

<http://slideplayer.com/slide/5282534/>

Transformada Wavelet

Simon Xu. (2015, agosto 28). *Easy Introduction to Wavelets* [Vídeo]. YouTube. <https://www.youtube.com/watch?v=ZnmvUCtUAEE>

En este vídeo se explica visualmente y con una breve explicación matemática qué son las Wavelets y cómo funcionan.




Accede al vídeo:

<https://www.youtube.com/embed/ZnmvUCtUAEE>

Transformada Gabor

F. (2015, marzo 14). *Gabor Transform of a sinusoidal signal* [Vídeo]. YouTube. <https://www.youtube.com/watch?v=xtFqBYY48FQ>

Este vídeo explica cómo realizar la transformada de Gabor a una señal sinusoidal.




Accede al vídeo:

<https://www.youtube.com/embed/xtFqBYY48FQ>

Transformada SIFT

UF CRCV. (2012, septiembre 19). *Lecture 05 - Scale-invariant Feature Transform (SIFT)* [Vídeo]. YouTube. <https://www.youtube.com/watch?v=NPcMS49V5hg>

Conferencia de Mubarak Shah en el que trata con profundidad la transformada SIFT (Scale Invariant Feature Transform).



Accede al vídeo:

<https://www.youtube.com/embed/NPcMS49V5hg>

Bibliografía

González, R. C. y Woods, R. E. (1992). *Digital image processing*. Boston: Addison-Wesley.

Mallat, S. G. (1998). *A wavelet tour of signal processing: The sparse way*. Cambridge: Academic Press.

1. ¿Qué algoritmo sirve para la extracción de características invariantes a rotación?
 - A. Los filtros de Gabor.
 - B. Las Wavelets.
 - C. El algoritmo SIFT.
 - D. Todas las anteriores.

2. ¿Qué limitación de la transformada de Fourier cubre la STFT?
 - A. Ninguna, ambas son transformadas de Fourier.
 - B. El hecho de que la transformada de Fourier no indica en qué momento se produce una determinada frecuencia.
 - C. Son más óptimas en procesamiento, como las FFT.

3. ¿Qué algoritmo es el más adecuado para el reconocimiento de texturas?
 - A. Los filtros de Gabor
 - B. Las Wavelets
 - C. El algoritmo SIFT
 - D. Todas las anteriores.

4. ¿Qué ventajas tiene el algoritmo SIFT?
 - A. Proporciona características invariantes a escala, rotación e intensidad.
 - B. Es muy eficiente y rápido de ejecutar.
 - C. Es capaz de crear pocas características, pero muy potentes.

5. SIFT significa:
 - A. Scale Invariant Feature Transform
 - B. Short-interval Fourier Transform
 - C. Small Invariant Fourier Transform.

6. ¿En qué casos emplearías un filtro de Gabor?
 - A. Reconocimiento de personas basado en la huella de la palma de la mano.
 - B. Reconocimiento de órganos humanos en una imagen biomédica.
 - C. Distinción entre asfalto y acera en un coche que conduce automáticamente.
 - D. Todas las anteriores.

7. ¿En qué casos emplearías Wavelets?
 - A. Para la parametrización de una señal sinusoidal constante.
 - B. Para la detección de un cambio de frecuencias en un momento determinado del tiempo.
 - C. Ambas son correctas.

8. ¿En qué casos emplearías SIFT?
 - A. Detección de campos de cultivo en una imagen realizada por helicóptero.
 - B. Detección de señales de tráfico en conducción automática.
 - C. Análisis de constelaciones de forma autónoma.

9. ¿Cuál es la principal desventaja de STFT?
 - A. El empleo de una ventana temporal constante a la hora de realizar el análisis de frecuencias.
 - B. Ninguno, es una transformada de Fourier mejorada y tiene todas las ventajas de dicha transformada.
 - C. No puede detectar texturas.

10. Ordena cronológicamente los algoritmos en función de su invención, creación y propuesta, de más antiguo a más reciente:

- A. Primero los filtros de Gabor, luego las Wavelets y por último SIFT.
- B. Los filtros de Gabor y las Wavelets primero (difícil de identificar cuál fue primero) y por último SIFT.
- C. Primero las Wavelets, luego los filtros de Gabor, que son un caso específico de las Wavelets, y por último SIFT.